Architecture matérielle

1. Le modèle de von Neumann


1.1. Le principe

John Von Neumann (1903-1957) est un ingénieur, mathématicien et physicien américano-hongrois. Il a participé au projet Manhattan (première bombe atomique) et à l'ENIAC. Son nom reste attaché à un modèle qu'il propose en 1944, modèle d'architecture novateur qui sert toujours de base à nos architectures actuelles.



Le **modèle de von Neumann** précise les 4 composants essentiels d'un microprocesseur ainsi que les interactions entre ces différents composants. Ces composants sont les suivants :

- l'unité de commande : contrôle la séquence d'instructions ;
- l'unité arithmétique et logique (UAL ou ALU en anglais) : exécute les instructions ;
- la mémoire : contient les données et les programmes ;
- l'unité d'entrée et sortie.




Cette architecture est bien entendu une architecture théorique. Elle doit être complétée par un certain nombre d'autres sousstructures pour être effectivement fonctionnelle. On distingue entre autres :

- Les bus sont les liaisons entre les différents éléments de l'architecture (mémoire, ALU, E/S,...).
- L'horloge est le cadenceur qui organise l'accomplissement des instructions, et dont l'unité est appelé cycle d'horloge (1 cycle = 1 instruction).

1.2. Cadence d'un processeur

La vitesse d'un processeur est exprimée en GigaHertz (GHz). Elle exprime le *nombre d'opérations que peut faire le processeur en une seconde*. Ainsi, un processeur à **3 GigaHerz** effectue **3 milliards d'opérations à la seconde**, c'est-à-dire 3 milliards de cycles par secondes.

L'augmentation de la fréquence d'horloge a longtemps été un attendu des progrès de l'informatique, et elle a été longtemps corrélée à l'augmentation du nombre de transistors dans les processeurs. Gordon E. Moore énonça en 1965 une loi empirique prédisant un doublement du nombre de processeurs tous les deux ans.



Mais cette augmentation génère une chaleur très importante au niveau processeur, la dissipation de cette chaleur étant rapidement devenue un problème. Depuis 2005 environ, les fabricants se sont plutôt tourné vers une **augmentation du nombre de cœurs** dans leurs processeurs, en comptant sur le **parallélisme**(le fait de pouvoir gérer des instructions en simultané sur plusieurs cœurs) pour augmenter le nombre d'instructions traitées par seconde, plutôt qu'une augmentation pure du nombre d'opérations par seconde, qui actuellement plafonne aux environs de $3,8\,\mathrm{GHz}$.



1.3. Cycles d'instructions et parallélisme

Dans un processeur, 5 étapes sont nécessaires pour traiter une instruction. Chacune de ces 5 étapes est exécutée :

- IF (Instruction Fetch): charge l'instruction à exécuter;
- ID (Instruction Decode) : décode l'instruction ;
- EX (Execute): exécute l'instruction;
- **MEM** (*Memory*): dénote un transfert depuis un registre vers la mémoire dans le cas d'une instruction du type STORE (accès en écriture) et de la mémoire vers un registre dans le cas d'un LOAD (accès en lecture);
- **WB** (*Write Back*): stocke le résultat dans un registre. La source de ce résultat peut être la mémoire (suite à une instruction LOAD), l'unité de calcul (suite à un calcul à l'étape EX) ou bien un registre (cas d'une instruction MOV).

En supposant que chaque étape met 1 cycle d'horloge pour s'exécuter, il faut normalement 5 cycles pour exécuter une instruction, 15 pour 3 instructions :



Il est cependant possible d'améliorer ce système, notamment par l'utilisation de **pipelines** dans des processeurs dits *superscalaires*. Si plusieurs opérations **d'un même programme sont indépendantes**, alors le processeur peut contenir plusieurs instructions, chacune à une étape différente. Le pipeline ci-dessous est le *Classic RISC pipeline*, créé par David Patterson, inventeur des processeurs RISC et du concept de pipeline, et mis en œuvre dès 1961 par IBM:



Il faut alors seulement 9 cycles pour exécuter 5 instructions. Au cinquième cycle, tous les étages du pipeline sont sollicités et les 5 opérations ont lieu en même temps.


1.4. L'évolution du modèle de von Neumann

Même si le modèle de von Neumann reste d'actualité, il a subi quelques évolutions récemment :




- Les Entrée-sorties sont contrôlées par des processeurs autonomes.
- Les CPU sont **multiprocesseurs**, soit par unités séparées soit par multiples cœurs dans une même puce. On a ainsi une augmentation de la puissance sans augmenter la vitesse des processeurs.
- La **mémoire** est au cœur du système, ce qui implique de plus en plus de parallélisme.

On peut voir cette évolution sur les processeurs eux-mêmes :



Nom	Année	Nombre de transistors	Vitesse d'horloge	Mémoire
Intel 4004	1971	2300	100 KHz	640 o




Nom	Année	Nombre de transistors	Vitesse d'horloge	Mémoire
Intel 8080	1974	4500	2 MHz	64 ko



Nom	Année	Nombre de transistors	Vitesse d'horloge	Mémoire
Motorola 68060	1994	2,5 millions	50 MHz	64 ko




Nom	Année	Nombre de transistors	Vitesse d'horloge	Mémoire
PowerPc 970Fx	2003	58 millions	1,6-2,7 GHz	2Mo Cache L2



Nom	Année	Nombre de transistors	Vitesse d'horloge	Mémoire
Intel Core I7 LGA1156	2009	+de 700 millions	2,3 à 3,8 GHz	12 Mo de cache L3

2. Les mémoires informatiques

2.1. La hiérarchie des mémoires



Dans un ordinateur, le processeur accède aux instructions du programme à exécuter ainsi qu'aux données nécessaires à son exécution depuis la mémoire.

Il existe une hiérarchie des mémoires informatiques : les **plus rapides sont les plus coûteuses**, donc en nombre limité, et sont **placées le plus près du processeur** (les registres font partie intégrante du processeur). Les plus lentes sont les moins coûteuses et sont éloignées du processeur.

Le matériel et le système d'exploitation sont responsables du déplacement des objets le long de cette hiérarchie.

A titre d'information, voici une illustration des capacités et du temps d'accès aux différentes mémoires (sur un processeur de 2012):

Туре	Capacités	Vitese
Registre	$\simeq 1000 o$	1 cycle
Cache L1	128 Ko	700 Go/s
Cache L2	1 Mo	200 Go/s
Cache L3	6 Mo	100 Go/s
Cache L4	128 Mo	40 Go/s

Туре	Capacités	Vitese
DRAM	$\simeq 8Go$	10 Go/s
HDD	Plusieurs To	200 Mo/s
SSD	500 Mo	600 Mo/s

2.2. Random Access Memory

La mémoire RAM (random Access Memory, aussi appelée mémoire vive, est un type de mémoire volatile, ce qui signifie qu'elle perd toutes les données en mémoire une fois l'alimentation électrique coupée. Elle est caractérisée par un accès direct aux données (on accède directement aux « cases » contenant les données), contrairement à un disque dur où l'accès se fait de manière séquentielle (on parcourt le disque pour arriver aux données cherchées). On distingue deux principaux types de mémoire RAM :

- la SRAM (Static Random Access Memory): dans la SRAM, les données sont stockées à l'aide de l'état d'une cellule mémoire composée de 6 transistors. La SRAM est généralement utilisée en guise de mémoire cache pour le processeur. La SRAM n'est généralement pas remplaçable par l'utilisateur.
- DRAM (Dynamic Random Acces Memory): la DRAM stocke les données à l'aide d'un transistor et d'un accumulateur, qui
 constituent une cellule de DRAM. La DRAM coute moins cher à produire, mais est légèrement moins rapide que la SRAM. La
 plupart des modules de mémoire remplaçables par l'utilisateur sont des modules DRAM.

On trouve parfois la mémoire ECC (Error Correcting Code, pour code correcteur d'erreur), qui est un type de mémoire qui dispose d'une cellule supplémentaire pour détecter et corriger les erreurs aléatoires. La mémoire ECC est remplaçable par l'utilisateur, mais doit être compatible avec les autres composants.

Au vu de l'accélération des différents composants informatiques, il a été nécessaire d'accélérer la mémoire qui devenait le maillon faible de la chaine de traitement des données. Le **débit de données double**, ou **DDR** (*Double Data Rate*) fut alors développé, et la technologie qu'il a remplacée fut appelée \« débit de données simple », ou SDR (*Single Data Rate*). La mémoire DDR était à la fois plus rapide et moins énergivore que la RAM SDR.

Les technologies de mémoire continuent d'évoluer. La génération de mémoire suivante, la DDR2, fonctionne à des vitesses supérieures et consomme moins d'énergie que la DDR originale. La DDR3 et la DDR4 ont également suivi cette tendance. Chaque génération successive est plus rapide et consomme moins d'électricité.

2.3. Read-Only Memory

Originellement, l'expression *mémoire morte* (en anglais, *Read-Only Memory*: ROM) désignait une mémoire informatique non volatile (c'est-à-dire une mémoire qui ne s'efface pas lorsque l'appareil qui la contient n'est plus alimenté en électricité) et dont le contenu est fixé lors de sa programmation, qui pouvait être lue plusieurs fois par l'utilisateur, mais ne pouvait plus être modifiée.

Avec l'évolution des technologies, la définition du terme mémoire morte (en français) ou read only memory (en anglais) a été élargie pour inclure les mémoires non volatiles dont le contenu est fixé lors de leur fabrication, qui peuvent être lues plusieurs fois par l'utilisateur et qui ne sont pas prévues pour être modifiées. Elles peuvent parfois cependant l'être par un utilisateur expérimenté, éventuellement avec un matériel spécial. Ces mémoires sont les UVPROM, les PROM, les EPROM et les EEPROM.

3. TP: programmer en assembleur

3.1. L'assembleur, késako?

Un programme écrit dans un langage de **haut niveau** (comme Python) éloigné du **langage machine** (dit de bas niveau) dépend le moins possible du processeur et du système d'exploitation.

Si on ouvre un fichier exécutable avec un éditeur hexadécimal, on obtient quelque chose du type

01ebe814063727473747566662e6305f5f43544f525f4c 5f05f5f44544f525f4c4953545f5f05f5f4a43525f4c49 53545f5f05f5f646f5f676c6f62616c5f64746f72735f6 75780636f6d706c657465642e36353331064746f725f69

C'est une suite d'instructions comme 01ebe814 que l'on peut traduire directement de façon plus lisible :

```
add R0, R1 , R2
```

C'est ce qu'on appelle de l'assembleur. Par exemple ici l'instruction add, va écrire dans le registre R0 la somme des valeurs des registres R1 et R2.

L'assembleur est donc une représentation du langage machine, mais qui est **dépendante directement du processeur** (ou de la famille du processeur). En effet, les différents processeurs ne reconnaissent pas exactement les mêmes types de mots clé, ni exactement la même syntaxe. De même le nombre de registres accessibles est très différent selon le processeur utilisé.

On peut distinguer deux grands types de processeurs. Les **processeurs RISC**' (Reduced instruction set computer ou processeur à jeu d'instructions réduit) sont des processeurs ou le nombre d'instructions est limité et ces instructions sont généralistes - opérations arithmétiques, chargement de données dans/vers les registres, opérations binaires de décalage de bits, etc. La conséquence de ce choix est le nombre restreint de circuits spécifiques sur le processeur, et donc le nombre restreint de transistors.

On trouve aussi les **processeurs de type CISC** ((*Complex Instruction Set Computer* ou processeurs à jeu d'instruction étendu). Ce sont les processeurs de type x86, AMD64, Intel64, dont la fabrication a été rendue possible par la miniaturisation des transistors et la capacité d'organiser finement les circuits afin d'avoir des circuits spécialisés.

En pratique, un langage de haut niveau est *compilé en assembleur* puis directement codé en binaire pur. La plupart des programmeuses et programmeur ne touchent jamais à l'assembleur, sauf dans des cas très précis où il est nécessaire d'être au plus près de la machine. Mais pour comprendre le fonctionnement d'un processeur, il est quand même important d'avoir quelques notions...

3.2. Le M99, un ordinateur en papier

D'après le travail de Martin Quinson, ENS-Rennes

Dans un premier temps, vous aurez besoin du processeur M99.

Le M99 est doté de 100 cases mémoire (la grille en haut), et d'un processeur (en bas). La **mémoire** est composée de 100 mots mémoire de 3 chiffres (valeur de 000 à 999). Chaque mot mémoire peut être désigné par une adresse codée sur deux chiffres. Cette mémoire va contenir données et instructions.\

L'Unité Arithmétique et Logique (ALU) : le processeur dispose de trois registres directement utilisables. A et B sont utilisé pour les opérandes des opérations tandis que R est pour le résultat. Ces registres sont de 3 chiffres, mais contrairement à la mémoire, ils ont un signe. Leur étendue de valeurs est donc comprise entre -999 et 999.

Le processeur dispose aussi d'un quatrième registre nommé PC (*Program Counter*). C'est le pointeur d'instruction, contenant l'adresse mémoire de la prochaine instruction à exécuter. Lorsqu'on utilise le M99, on peut noter le numéro de l'instruction à exécuter dans la case prévue à cet effet, mais en pratique, il est plus simple de le matérialiser avec un \« pion» situé sur une des cases de la grille mémoire, ou même de simplement suivre avec son doigt.

Le jeu d'instruction est défini ci-dessous :

Code	$Mn\'emonique$	Instruction à réaliser
0 x y	STR xy	Copie le contenu du registre R dans le mot mémoire d'adresse xy
1 x y	LDA xy	Copie le mot mémoire d'adresse xy dans le registre A
2 x y	LDB xy	Copie le mot mémoire d'adresse xy dans le registre B
3 x y	MOV x y	Copie registre Rx dans Ry (R0 : R; R1 : A; R2 : B)
4 0 0	ADD	Ajoute les valeurs des registres A et B, produit le résultat dans R
4 0 1	SUB	Soustrait la valeur du registre B à celle du registre A, produit le résultat dans R
4 x y	etc	(d'autres opérations arithmétiques et logiques peuvent être encodées ainsi)
5 x y	JMP x y	Branche (saute) en xy (PC reçoit la valeur xy)
6 x y	JPP x y	Branche en xy si la valeur du registre R est positive
7 x y	JEQ x y	Saute une case (PC++) si la valeur du registre R est égale à xy
8 x y	JNE x y	Saute une case (PC++) si la valeur du registre R est différent de xy

Ainsi on a les codes suivants :

- ullet 245 qui se traduit en LDB 45 , soit « Charger le contenu de la case mémoire 45 dans le registre B » ;
- $312\,\mathrm{qui}$ se traduit en MOV 12 , soit « Copier le contenu du registre B dans le registre A » .



Lire et écrire un programme en assembleur

Énoncé

Sur le processeur M99 fourni, deux différents programmes sont déjà en mémoire.

- 1. Dérouler « à la main » le programme chargé à l'adresse 00. Quel est le résultat obtenu ? Quel est l'objectif de ce programme ?
- 2. Dérouler « à la main » le programme chargé à l'adresse 13. Quel est le résultat obtenu ? Quel est l'objectif de ce programme ?
- 3. Écrire un programme sur le M99, chargé en adresse 40, qui prend deux nombres en entrée (l'entrée étant considéré comme étant tout nombre mis en case 99) et renvoie la somme de ces deux nombres en sortie.

Solution

A venir!

3.3. Utilisation d'un simulateur RISC

D'après le travail de David Roche

Afin de mettre en pratique ce que nous avons étudié dans le cours, nous allons utiliser un simulateur de processeur RISC développé en Javascript par Peter L Higginson. Ce simulateur est basé sur une architecture de von Neumann. Nous allons trouver dans ce simulateur une RAM et un CPU.

Une version en français de ce simulateur est disponible ici sous la forme d'un dossier compressé.

Voici ce que vous devriez obtenir :



Il est relativement facile de distinguer les différentes parties du simulateur :

- à droite, on trouve la mémoire centrale;
- au centre, on trouve le microprocesseur;
- à gauche on trouve la zone d'édition (« Code assembleur»), c'est dans cette zone que nous allons saisir nos programmes en assembleur.

Plus spécifiquement :

• pour la **RAM**, par défaut le contenu des différentes cellules de la mémoire est en base 10 (entier signé), mais d'autres options sont possibles : base 10 (entiers non-signés), base 16 (hexadécimal), base 2 (binaire). On accède à ces options à l'aide du bouton OPTIONS situé en bas dans la partie gauche du simulateur.



Exercice

Énoncé

À l'aide du bouton OPTIONS, passez à un affichage en binaire. Quelle est la taille des mots utilisés dans ce simulateur? Combien y-a-t'il de cases mémoires?

Réponse

A venir!

- pour Le CPU, dans la partie centrale du simulateur, nous allons trouver en allant du haut vers le bas :
 - le bloc « Registres», où nous avons 8 registres (RØ à R7) + 1 registre (PC) qui contient l'adresse mémoire de l'instruction en cours d'exécution ;
 - le bloc « Unité de Contrôle» qui contient l'instruction machine en cours d'exécution (au format hexadécimal) ;
 - le bloc « Unité Arithmétique et Logique», qui effectuera les opérations.

Nous ne nous intéresserons pas aux autres composants de la partie CPU.



Énoncé

1. Avec le bouton OPTIONS, repassez en entiers signés, puis, dans la partie \« Code assembleur », saisissez les lignes de codes suivantes :

```
MOV R0, #42
STR R0, 150
```

Cliquez sur le bouton Valider. Que se passe-t-il?

2. Pour exécuter notre programme, il suffit maintenant de cliquer sur le bouton LANCER. Vous allez voir le CPU \« travailler » en direct grâce à de petites animations. Si cela va trop vite (ou trop doucement), vous pouvez régler la vitesse de simulation à l'aide des boutons << et >> . Un appui sur le bouton STOP met en pause la simulation, si vous rappuyez une deuxième fois sur ce même bouton STOP, la simulation reprend là où elle s'était arrêtée. Vous pouvez aussi lancer la simulation pas à pas grâce au bouton PAS, et réinitialiser avec le bouton REINIT. Attention, la mémoire n'est pas modifiée par un appui sur le bouton REINIT, pour remettre la mémoire à 0, il faut cliquer sur le bouton OPTIONS et choisir réinit. mémoire . Si vous remettez votre mémoire à 0, il faudra cliquer sur le bouton ASSEMBLER avant de pouvoir exécuter de nouveau votre programme.

Qu'obtient-on à la fin de l'exécution?

- 1. Modifiez le programme précédent pour qu'à la fin de l'exécution on trouve le nombre 54 à l'adresse mémoire 50. On utilisera le registre R1 à la place du registre R0. Testez vos modifications en exécutant la simulation.
- 2. Saisissez et testez le programme suivant :

```
MOV R0, #4
STR R0,30
MOV R0, #8
STR R0,75
LDR R0,30
CMP R0, #10
BNE 10
MOV R0, #9
STR R0,75
BRA 13
LDR R0,30
ADD R0, #1
STR R0,30
MOV R0, #6
STR R0,23
```

- a. Quels sont les changements apportés à la mémoire après avoir exécuté ce code ?
- b. Que se passe-t-il après l'exécution de la ligne BNE 10 ? Pourquoi?
- c. Modifier la première ligne du code avec :

```
MOV R0, #10
```

Quels sont les changements apportés à la mémoire après avoir exécuté ce code ?

- d. Que se passe-t-il après l'exécution de la ligne BNE 10 ? Pourquoi?
- 3. Pour les courageux, voici un programme simple en Python:

```
x = 0
while x < 3 :
    x = x+1</pre>
```

Traduisez-le en assembleur.